



דוח הערכה

ניהול צריכה באמצעות סריקת חשבוניות קבלה

נופר גרשוני-322773680 עלית בן חמו-206851081 למנחה-גב' קרן סגל

תוכן עניינים:

3	1. הערכת התוצאות:
5	שאלות חדשות שנולדו מהתהליך
6	יתרונות מודל SVM
6	2.תהליך הסקירה:
7	הצלחות:
7	חולועות:

1. הערכת התוצאות:

בשלב זה גובשה הערכה כוללת, האם תוצאות הפרויקט עומדות בקריטריונים של הצלחה עסקית, כפי שהוגדרו בתחילת הדרך – כלומר, האם הכלים והמודלים שפותחו מצליחים לזהות באופן מדויק ומועיל אי-התאמות בכמויות הרכישה של לקוחות. הערכה זו קריטית, שכן היא משקפת את יכולתו של המודל לתרום להבנה עמוקה של התנהגות צרכנית ולשמש כלי אפקטיבי, בקרה ואיתור אי-התאמות.

הנתונים שהופקו מהמודלים הוצגו באופן ברור באמצעות טבלאות מסודרות, תוך (Accuracy ו-Precision, Recall, F1-Score). טבלאות אלו שימשו כאמצעי מרכזי להצגת הביצועים של כל מודל, וסיפקו תמונה כמותית ומושגית ברורה באשר ליכולתו לזהות מקרים של אי-התאמה בכמות הרכישה. מאחר וההצגה נעשתה בצורה ברורה ואחידה, ניתן היה להשוות בין המודלים בקלות ולבחון את תרומתם הישירה למטרות העסקיות שהוגדרו.

במהלך תהליך הניתוח, זוהו ממצאים חדשים בעלי ערך מוסף גבוה. בין ממצאים אלו ניתן לציין לקוחות אשר התנהגותם הצרכנית חורגת מהיסטוריית הרכישות שלו. לדוגמה, לקוחות שרכשו לפתע כמויות משמעותית גבוהות או נמוכות מהממוצע שלהם. חריגות אלה חושבו בהתאם לטווח שהוגדר על בסיס ממוצע הרכישה וסטיית התקן של כל לקוח בנפרד. תובנות אלו מצביעות על דפוסים בלתי שגרתיים, אשר עשויים להעיד על אי- התאמה בכמות הרכישה.

מודלים אלו תורמים תרומה משמעותית לאיתור מוקדם של חריגות, אשר עשויות לאותת על כשלים או שינויים הדורשים תשומת לב. כך, לדוגמה, ניתן לאתר מקרים שבהם נרשמה כמות רכישה כפולה מהרגיל. מודלים אלה משמשים ככלי לבחינה שיטתית של כל לקוח בנפרד, ומספקים תובנה מדויקת באשר לנורמליות או חריגות ברכישה.

התרומה העסקית של הממצאים באה לידי ביטוי ביכולת לייעל את מערך הבקרה על הרכישות ולתמוך החלטות מבוססות נתונים. באמצעות המודלים, ניתן לבנות מנגנון שפועל על נתוני רכישה חדשים לצורך השוואה מול דפוסי העבר, ולזהות מקרים בהם כמות הרכישה אינה תואמת את הציפייה. תהליך זה עשוי לשמש לצורך בקרת איכות פנימית, בדיקת אמינות של עסקאות.

תוצאות המודלים מספקות מענה ישיר ומדויק למטרה המרכזית – זיהוי חריגות ואי-התאמות בכמויות הרכישה. המודלים מאפשרים לנתח לעומק את דפוסי הרכישה של כל לקוח, לזהות מתי חלה חריגה מהתנהגות הרכישה הרגילה שלו.

<u>-test=0.3 train=0.7 חלוקה לפי פרמטרים</u>

Silhouette	Accuracy	F1 Score	Recall	Precision	מודל
-	0.996	0.968	0.989	0.947	מכונת וקטורים תומכת(SVM)
-	0.991	0.932	0.978	0.889	עצי החלטה
-	0.960	0.742	0.956	0.607	Radom Forest
0.74	-	-	-	-	k-means

דירגנו את המודלים על פי מידת תרומתם להשגת מטרת הפרויקט – זיהוי מדויק של אי-התאמות בכמויות הרכישה של לקוחות. הדירוג המתבסס על רמת הדיוק של המודלים, יציבות התוצאות, והיכולת להפיק מהם תובנות משמעותיות. ניתנה עדיפות למודלים שהפגינו ביצועים גבוהים בזיהוי חריגות בהשוואה לדפוס הרכישה ההיסטורי של כל לקוח.

המודלים הוערכו על פני מספר הרצות שונות, שכללו חלוקות שונות של הנתונים לקבוצות אימון ובדיקה, במטרה לבחון את העקביות של התוצאות. תהליך זה אפשר להתמקד במודלים שמציגים ביצועים אמינים, מבססים את המסקנות שהופקו מהם, למשל, היכולת לזהות לקוחות בעלי אי- התאמות ברורות בכמות הרכישה ביחס להתנהגות ההיסטורית שלהם.

תובנות אלו מספקות תמונה רחבה ומעמיקה של חריגות ברמת הלקוח, מהווה בסיס להמשך ניתוחים בתחום, כמו בדיקת מגמות חוזרות בדפוסי רכישה.

שאלות חדשות שנולדו מהתהליך

במהלך הניתוח עלו שאלות נוספות אשר מצביעות על כיווני מחקר עתידיים, לדוגמה:

אילו משתנים תורמים באופן מובהק להופעת אי-התאמה בכמות הרכישה?

צריך לבדוק אילו מאפיינים של הרכישות הקודמות של כל לקוח קשורות לכך שכמות הרכישה שלו יוצאת מהרגיל. למשל, האם הממוצע של הכמויות שהוא קונה בדרך כלל, או כמה משתנה הכמות שלו (האם הוא קונה כמויות דומות כל פעם או יש שינויים גדולים), יכולים לעזור להבין מתי וכיצד מתרחשת חריגה. הבנת הגורמים האלה תעזור לזהות מתי תתבצע אי- התאמה בכמות הרכישה.

<u>האם קיימים דפוסים תקופתיים או עונתיים באי- התאמות?</u>

יש לבדוק האם אי-התאמות בכמויות הרכישה מתרחשות במועדים או בתקופות מסוימות – לדוגמה, אם הן חוזרות על עצמן באופן מחזורי או שמדובר באירועים אקראיים. זיהוי דפוסים תקופתיים יכול לסייע להבחין בין אי-התאמות צפויות לבין כאלה שיכולות להצביע על בעיה או חריגה משמעותית בהתנהגות הצרכנית.

<u>כיצד משתנים דפוסי אי- התאמה בכמות הרכישה בקרב לקוחות שונים לאורך זמן?</u>

חשוב לנתח כיצד דפוסי אי-ההתאמות משתנים עבור כל לקוח בנפרד לאורך זמן –
האם יש לקוחות עם אי-התאמות חוזרות או כאלה שמופיעות באופן חד-פעמי, האם
חלה עלייה או ירידה במידת אי-ההתאמה לאורך התקופה. ניתוח כזה עשוי להצביע
על התפתחות של בעיות או אירועים יוצאי דופן ספציפיים ללקוח.

שאלות אלו עשויות להוביל להעמקה בניתוח, לאיתור גורמים סמויים שלא נבחנו עד כה, תוך שיפור יכולת החיזוי וההבנה של תופעות צרכניות מורכבות.

-SVM – המודל בעל הביצועים הגבוהים ביותר

מבין כלל המודלים שנבחנו, מודל ה־SVM הציג את הביצועים הגבוהים ביותר בזיהוי חריגות בכמות הרכישה. המודל הדגים רמת דיוק מרשימה ביצירת הבחנה בין רכישות תקינות לחריגות.

יתרונות מודל SVM:

דיוק גבוה בזיהוי אי-התאמות: המודל הצליח לזהות חריגות על סמך חריגה מהתנהגות היסטורית בצורה מדויקת, תוך הפחתת כמות הזיהויים השגויים.

יכולת הכללה טובה: SVM הראה יציבות גם מול נתונים חדשים שלא נצפו קודם לכן, בזכות השימוש בגבולות הפרדה מיטביים.

התמודדות עם מקרים לא ליניאריים: באמצעות גרעינים (kernels), המודל הצליח ללמוד דפוסים מורכבים גם כאשר הקשרים בין המשתנים אינם ליניאריים.

פשטות יחסית בהפעלה: למרות היכולות המתקדמות שלו, המודל ניתן ליישום ולהבנה גם בתצורות פשוטות יחסית.

2.תהליך הסקירה:

תהליך הסקירה הוא שלב מרכזי בפרויקט, שבו בחנו את מה שהצלחנו להשיג מול הקשיים שנתקלנו בהם במהלך העבודה. מטרת התהליך היא להבין מה עבד היטב ומה ניתן לשפר, כדי להפיק לקחים. בסקירה התייחסנו להחלטות שקידמו את הצלחת הפרויקט – כמו הגדרת מטרות ברורה, בחירת מודלים מתאימים והצגת ממצאים באופן ברור. דרך בחינה זו הפקנו תובנות פרקטיות, המאפשרות לשפר את אופן ניתוח הנתונים ואת שיטות זיהוי של אי-התאמות בכמות הרכישה.

הצלחות:

הגדרת מטרות ברורה:

בתחילת הפרויקט הוגדרו בצורה מדויקת מטרות העבודה ובפרט, זיהוי של אי-התאמות בכמויות הרכישה על בסיס נתוני עבר. הגדרה ברורה זו סייעה לכוון את תהליך העבודה, לבחור את שיטות הניתוח והמודלים המתאימים ביותר. התאמה בין מטרות הפרויקט לבין שלבי הניתוח תרמה רבות להשגת תוצאות ממוקדות ומבוססות.

יישום שיטתי של שלבי הניתוח:

במהלך העבודה נשמר רצף שיטתי בהתאם למטרות שהוגדרו. בחנו חלוקות שונות של הנתונים, הערכנו ביצועי מודלים באופן מבוקר, התמקדנו בזיהוי תבניות המעידות על חריגות ביחס לדפוסי הרכישה הרגילים של כל לקוח.

ויזואליזציה:

הצגנו גרפים והדמיות ברורות אשר המחישו את דפוסי הרכישה של לקוחות. בגרפים אילו היה ניתן לזהות מתי לקוח חרג מהטווח התקין, שהוגדר על סמך ממוצע הרכישות וסטיית התקן. הייצוג הוויזואלי איפשר להבין חריגות נקודתיות לעומת מגמות חוזרות לאורך זמן, והפך את התובנות לנגישות גם עבור מי שאינו בקיא בניתוח נתונים. הצגה זו תרמה לקבלת החלטות מדויקת וממוקדת יותר בהתבסס על ראיות חזותיות.

חולשות:

איכות הנתונים:

במהלך הפרויקט התמודדנו עם מגבלות הקשורות למבנה הנתונים ולמגוון המאפיינים שעמדו לרשותנו. אמנם לא נמצאו ערכים חסרים, אך זיהינו צורך בהעמקת המידע הקיים לצורך ניתוח מדויק של אי-התאמות בכמות הרכישה. לשם כך, גזרנו משתנים חדשים מהמאפיינים המקוריים לדוגמה, חישוב הפרשים בין כמויות רכישה, זיהוי רכישה מקסימלית ומינימלית לכל לקוח ועוד. יצירת משתנים אלו תרמה לשיפור משמעותי ביכולת המודלים לזהות דפוסים חריגים.

מדרגתיות וגמישות:

למרות שהמודלים שפיתחנו הצליחו לזהות אי-התאמות בצורה יעילה, ייתכן כי קיימות מגבלות בהרחבה שלהם בהתאמה לתנאים משתנים. ככל שהנתונים התעדכנו והתרחבו לאורך זמן, נדרש להבטיח שהמודלים יוכלו להסתגל לשינויים בדפוסי הרכישה ולמאפיינים חדשים של הלקוחות.

למידה ושיפורים עתידיים:

ניהול פרויקט משופר:

במהלך העבודה זיהינו כי תכנון מוקדם מדויק של שלבי העבודה היה יכול לתרום לייעול התהליך, במיוחד בכל הנוגע לחלוקת זמן בין שלבי עיבוד הנתונים, בניית מודלים וניתוח התוצאות.

:התאמת מודלים

על מנת לשמר את יכולת הזיהוי של אי-התאמות בכמות הרכישה לאורך זמן, יש לעדכן את הנתונים באופן שוטף ולבצע מעקב רציף של ביצועי המודלים. בנוסף, מומלץ לבחון שילוב של מסגרות למידת מכונה גמישות ומתקדמות יותר, שיאפשרו למודלים להסתגל לשינויים בדפוסי הצריכה ולזהות באופן מדויק חריגות גם כאשר התנאים משתנים.